

Análisis de Riesgo Crediticio y Morosidad de Préstamos

Documentación Técnica del Proyecto

Autor:

Luis Adrián Gámez Saucedo

Ingeniero Industrial | Business Intelligence & Data Analytics

Herramientas:

- Google BigQuery
 - SQL
 - Power BI
 - Microsoft Excel (Validación)
 - Kaggle
-

Fuente de Datos:

Credit Risk Dataset

Autor: Lao Tse

Plataforma: Kaggle

Fecha:

26 de Julio del 2026

Versión:

Versión 1.0

Resumen Ejecutivo

El presente proyecto tiene como objetivo analizar el riesgo crediticio de los clientes de una institución financiera mediante el uso de técnicas de análisis de datos. A partir de un conjunto de datos obtenido de Kaggle, se realizará un proceso integral que comprende la preparación, limpieza, transformación y análisis de la información utilizando Google BigQuery y SQL, para posteriormente desarrollar un dashboard interactivo en Power BI.

El análisis buscará identificar los principales factores asociados al incumplimiento de préstamos, evaluar el comportamiento de los clientes según sus características demográficas y financieras, y generar indicadores que apoyen la toma de decisiones en el proceso de otorgamiento de créditos.

Finalmente, los resultados serán presentados mediante visualizaciones y recomendaciones de negocio orientadas a mejorar la evaluación del riesgo crediticio y fortalecer el proceso de toma de decisiones basado en datos.

1.0 Entendimiento del Negocio

1.1 Antecedentes del Proyecto

Las instituciones financieras enfrentan constantemente el desafío de equilibrar el crecimiento de su cartera de préstamos con el control del riesgo crediticio. Otorgar créditos a clientes con alta probabilidad de incumplimiento puede generar pérdidas económicas y afectar la rentabilidad de la institución.

En este contexto, el análisis de datos permite identificar patrones de comportamiento, factores de riesgo y características comunes entre los clientes, facilitando una toma de decisiones más informada durante el proceso de evaluación y aprobación de créditos.

1.2 Problema de Negocio

Las instituciones financieras enfrentan constantemente el desafío de equilibrar el crecimiento de su cartera de préstamos con el control del riesgo crediticio. Otorgar créditos a clientes con alta probabilidad de incumplimiento puede generar pérdidas económicas y afectar la rentabilidad de la institución.

En este contexto, el análisis de datos permite identificar patrones de comportamiento, factores de riesgo y características comunes entre los clientes, facilitando una toma de decisiones más informada durante el proceso de evaluación y aprobación de créditos.

1.3 Objetivo General

Analizar la información del conjunto de datos de riesgo crediticio para identificar los principales factores asociados al incumplimiento de préstamos, mediante técnicas de limpieza, transformación y análisis de datos utilizando SQL en Google BigQuery, con el propósito de generar información útil para apoyar la toma de decisiones en el proceso de evaluación crediticia.

1.4 Objetivos Específicos

- Evaluar la calidad de los datos mediante un proceso de auditoría y limpieza.
- Transformar el conjunto de datos para facilitar su análisis.
- Identificar patrones relacionados con el incumplimiento de préstamos.
- Analizar el comportamiento de los clientes según variables demográficas y financieras.
- Desarrollar indicadores clave de desempeño (KPIs) para la evaluación del riesgo crediticio.
- Diseñar un dashboard interactivo en Power BI para comunicar los principales hallazgos.
- Proponer recomendaciones de negocio basadas en los resultados obtenidos.

1.5 Stakeholders

Los principales interesados en este análisis son las áreas involucradas en el proceso de otorgamiento y administración de créditos dentro de una institución financiera. Los resultados obtenidos pueden apoyar la toma de decisiones relacionadas con la evaluación del riesgo, la aprobación de préstamos y la gestión de la cartera de clientes.

Los stakeholders considerados para este proyecto son:

- Gerencia de Riesgo Crediticio.
- Analistas de Riesgo.
- Gerencia Comercial.
- Dirección Financiera.
- Equipo de Business Intelligence.

1.6 Preguntas de Negocio

- ¿Cuál es la tasa de incumplimiento de préstamos dentro del conjunto de datos?
- ¿Qué características presentan los clientes con mayor riesgo de incumplimiento?
- ¿Existe relación entre el nivel de ingresos y el riesgo crediticio?
- ¿Cómo influye la edad del cliente en el incumplimiento de préstamos?
- ¿Qué tipo de vivienda presenta mayor riesgo?
- ¿Qué nivel educativo está asociado con una mayor tasa de incumplimiento?
- ¿Qué variables parecen tener mayor impacto en el riesgo crediticio?
- ¿Qué indicadores pueden apoyar la toma de decisiones durante el proceso de evaluación de créditos?

1.7 Indicadores Clave de Desempeño (KPIs)

Para evaluar el comportamiento del riesgo crediticio se definirán los siguientes indicadores:

- Total de clientes analizados.
- Total de préstamos registrados.
- Tasa de incumplimiento.
- Tasa de cumplimiento.
- Ingreso promedio de los clientes.
- Monto promedio de los préstamos.
- Distribución de clientes por nivel de riesgo.
- Distribución de clientes por tipo de vivienda.
- Distribución por nivel educativo.
- Perfil del cliente con mayor riesgo.

1.8 Alcance del Proyecto

El presente proyecto comprende el análisis de un conjunto de datos de riesgo crediticio utilizando Google BigQuery, SQL y Power BI. El trabajo incluye la preparación, auditoría, limpieza, transformación y análisis de los datos, así como el desarrollo de un dashboard interactivo para comunicar los principales hallazgos.

El proyecto tiene un enfoque analítico y descriptivo, por lo que no contempla el desarrollo de modelos predictivos de Machine Learning.

2. Preparación de los Datos

2.1 Carga y comprensión inicial del dataset

El conjunto de datos fue importado a Google BigQuery para realizar el proceso de exploración, auditoría, limpieza y análisis mediante SQL.

Como primer paso, se realizó una revisión general del dataset con el objetivo de comprender su estructura, identificar la unidad de análisis y conocer las variables disponibles antes de iniciar cualquier transformación de datos.

Durante esta etapa se identificó que el dataset contiene 32,581 registros, distribuidos en 12 variables, las cuales describen tanto las características del solicitante como las características del préstamo otorgado.

La unidad de análisis corresponde a un préstamo asociado a un cliente, donde cada registro almacena información demográfica, financiera y crediticia del solicitante, además del resultado del préstamo.

2.2 Comprensión del Negocio

Antes de comenzar el análisis estadístico y la limpieza de datos, se clasificaron las variables según la información de negocio que representan.

Variables del cliente:

- person_age
- person_income
- person_emp_length
- cb_person_default_on_file
- cb_person_cred_hist_length

Estas variables describen las características personales y financieras del solicitante, así como parte de su historial crediticio.

Variables del préstamo:

- loan_amnt
- loan_int_rate
- loan_grade
- loan_intent
- loan_percent_income

Estas variables describen las características propias del préstamo solicitado, incluyendo su monto, tasa de interés, clasificación de riesgo y finalidad.

Variable objetivo

- loan_status

Esta variable representa el resultado del préstamo y será la principal variable de estudio durante el análisis, ya que permitirá identificar qué factores pueden estar asociados al incumplimiento o cumplimiento del crédito.

2.3 Auditoría inicial de calidad de datos

Como parte del proceso de preparación, se realizó una auditoría preliminar para identificar posibles problemas de calidad de datos antes de iniciar el análisis exploratorio.

La primera revisión se enfocó en la variable loan_int_rate, debido a que durante la inspección inicial se observaron valores faltantes.

Los resultados obtenidos fueron los siguientes:

Métrica	Resultado
----------------	------------------

Total de registros	32,581
--------------------	---------------

Valores nulos en loan_int_rate	3,116
-----------------------------------	--------------

Porcentaje de valores nulos	9.56 %
--------------------------------	---------------

Debido a que aproximadamente uno de cada diez registros presenta un valor faltante en esta variable, se decidió realizar un análisis adicional para determinar si dichos valores seguían algún patrón relacionado con el estado del préstamo.

Como primer acercamiento, se analizó la distribución de los registros con valores nulos según la variable loan_status.

loan_stat us	Registros con loan_int_rate nulo
-------------------------	---

0	2,472
---	--------------

1	644
---	------------

A partir de estos resultados se observó que la mayor cantidad de valores nulos corresponde a préstamos con loan_status = 0. Sin embargo, esta observación se basa únicamente en cantidades absolutas, por lo que aún no es posible concluir que exista una relación entre ambas variables. Como siguiente paso será necesario comparar estos resultados con el total de registros de cada categoría para evaluar los porcentajes correspondientes antes de tomar decisiones sobre el tratamiento de los valores faltantes.

2.4 Auditoría de registros duplicados

Como parte de la auditoría de calidad de datos, se realizó una búsqueda de registros completamente duplicados utilizando todas las variables del dataset como criterio de comparación.

Los resultados mostraron la existencia de **165 combinaciones de registros duplicados**, donde cada combinación aparece exactamente dos veces.

Métrica	Resultado
Combinaciones duplicadas	165
Registros involucrados	330
Registros excedentes	165

Esto indica la existencia de **165 registros redundantes** que potencialmente podrían eliminarse, conservando una única copia de cada combinación para evitar sesgos durante el análisis estadístico y las etapas posteriores del proyecto.

No obstante, **en esta etapa no se realizará ninguna modificación sobre los datos**. Antes de eliminar los registros duplicados, será necesario evaluar si dichas duplicaciones corresponden a errores de calidad de datos o a eventos legítimos registrados más de una vez por razones de negocio. Esta decisión será documentada y justificada durante la fase **PROCESS**, donde se llevará a cabo la limpieza del conjunto de datos.

2.5 Validación de tipos de datos

Se revisó el esquema del conjunto de datos en Google BigQuery con el objetivo de verificar que cada variable estuviera almacenada utilizando un tipo de dato consistente con la información que representa.

La revisión confirmó que las variables numéricas, categóricas y booleanas presentan tipos de datos adecuados para su posterior análisis y transformación.

No fue necesario realizar conversiones (CAST) ni modificaciones en los tipos de datos, por lo que el esquema del dataset se considera consistente para las siguientes etapas del proyecto.

2.6 Validación de variables categóricas

Se analizaron los valores únicos de la variable **person_home_ownership** con el objetivo de verificar la consistencia de sus categorías.

Se identificaron cuatro categorías válidas:

- RENT
- MORTGAGE
- OWN
- OTHER

No se encontraron inconsistencias relacionadas con diferencias de escritura, espacios en blanco o categorías duplicadas.

La distribución de los registros es la siguiente:

Categoría	Registros
RENT	16,446
MORTGAGE	13,444
OWN	2,584
OTHER	107

Con base en estos resultados, **no fue necesario aplicar procesos de estandarización o limpieza** para esta variable.

Variable: **loan_intent**

Se revisaron los valores únicos de la variable **loan_intent** con el objetivo de verificar la consistencia de las categorías registradas.

Se identificaron las siguientes categorías:

- EDUCATION
- MEDICAL

- VENTURE
- PERSONAL
- DEBTCONSOLIDATION
- HOMEIMPROVEMENT

No se encontraron inconsistencias relacionadas con diferencias en mayúsculas y minúsculas, espacios en blanco, errores de escritura o categorías duplicadas, por lo que **no fue necesario realizar procesos de limpieza o estandarización** para esta variable.

Asimismo, se analizó la distribución de los registros por categoría, observándose una distribución relativamente equilibrada entre las distintas finalidades del préstamo. Aunque **EDUCATION** concentra el mayor número de registros y **HOMEIMPROVEMENT** el menor, no se identificó una concentración desproporcionada en una sola categoría que pudiera representar un problema de calidad de los datos.

Variable: loan_grade

Se revisaron los valores únicos de la variable **loan_grade** con el objetivo de verificar la consistencia de las categorías registradas.

Se identificaron siete categorías válidas, correspondientes a las clasificaciones **A, B, C, D, E, F y G**.

No se detectaron inconsistencias relacionadas con diferencias en la escritura, espacios en blanco o categorías fuera del rango esperado, por lo que **no fue necesario realizar procesos de limpieza o estandarización** para esta variable.

Asimismo, se analizó la distribución de los registros por categoría, observándose una mayor concentración en los grados **A y B**, mientras que las categorías **F y G** presentan una participación considerablemente menor dentro del conjunto de datos. Esta distribución no representa un problema de calidad de datos, por lo que la variable se considera apta para las siguientes etapas del análisis.

2.7 Validación de variables numéricas

Con el objetivo de verificar la consistencia de los valores numéricos registrados en el conjunto de datos, se revisaron los rangos mínimo y máximo de cada variable cuantitativa. Esta validación permitió identificar posibles anomalías, valores fuera de lo esperado y registros que podrían requerir un análisis más detallado antes de la etapa de limpieza de datos.

Variable: person_age

Se revisó el rango de valores de la variable **person_age** para verificar que las edades registradas fueran coherentes con el contexto del análisis de riesgo crediticio.

Se identificó una edad mínima de **20 años** y una edad máxima de **144 años**.

La edad mínima se considera consistente con la población objetivo del conjunto de datos. Sin embargo, la edad máxima representa un valor atípico que podría corresponder a un error de captura o registro, por lo que será analizada con mayor detalle durante la etapa de procesamiento de datos.

Variable: person_income

Se revisó el rango de ingresos anuales registrados en la variable **person_income**.

Se identificó un ingreso mínimo de **4,000** y un ingreso máximo de **6,000,000**.

Aunque el ingreso máximo representa un valor considerablemente superior al resto de la población, no puede clasificarse como un error únicamente con base en su magnitud, ya que podría corresponder a un cliente con ingresos excepcionalmente altos. Por ello, este valor será evaluado posteriormente mediante técnicas de detección de valores atípicos.

Variable: person_emp_length

Se revisó el rango de la variable **person_emp_length**, correspondiente a la antigüedad laboral del solicitante.

Se identificó un valor mínimo de **0 años** y un valor máximo de **123 años**.

El valor máximo representa una posible inconsistencia, ya que excede ampliamente una antigüedad laboral esperada para cualquier persona. Debido a ello, esta variable será revisada con mayor detalle durante la fase de limpieza de datos.

Variable: loan_amnt

Se revisó el rango de los montos de préstamo registrados en la variable **loan_amnt**.

Los valores observados oscilan entre **500** y **35,000**, rango que resulta consistente con el contexto del conjunto de datos. No se identificaron valores que sugieran anomalías o problemas de calidad.

Variable: **loan_int_rate**

Se revisó el rango de la variable **loan_int_rate**, correspondiente a la tasa de interés aplicada al préstamo.

Los valores registrados se encuentran entre **5.42%** y **23.22%**, rango que resulta coherente para productos de crédito al consumo. No se detectaron valores fuera de los límites esperados; sin embargo, previamente se identificó la existencia de valores nulos, los cuales serán tratados durante la fase de procesamiento.

Variable: **loan_percent_income**

Se revisó el rango de la variable **loan_percent_income**, que representa la proporción del ingreso anual comprometida por el monto del préstamo.

Los valores registrados oscilan entre **0.00** y **0.83**, indicando que el préstamo representa desde un porcentaje muy pequeño hasta el **83% del ingreso anual** del solicitante. El rango observado se considera consistente y no evidencia anomalías de calidad de datos.

Variable: **cb_person_cred_hist_length**

Se revisó el rango de la variable **cb_person_cred_hist_length**, correspondiente a la antigüedad del historial crediticio del solicitante.

Los valores registrados se encuentran entre **2** y **30 años**, rango que resulta consistente con el contexto del análisis y no presenta indicios de inconsistencias o errores de captura.

2.8 Conclusión

Durante la fase de preparación de los datos se realizó una auditoría integral del conjunto de datos con el objetivo de evaluar su calidad, estructura y consistencia antes de iniciar el proceso de limpieza y transformación.

Se verificó la estructura del dataset, los tipos de datos, la presencia de valores nulos, registros duplicados y la consistencia de las variables categóricas y numéricas. Como resultado de esta revisión, se identificaron **165 registros completamente duplicados**, valores nulos en la variable **loan_int_rate** y posibles anomalías en las variables **person_age** y **person_emp_length**, las cuales serán analizadas y tratadas durante la siguiente fase del proyecto.

En términos generales, el conjunto de datos presenta una calidad adecuada para continuar con el proceso analítico, requiriendo únicamente acciones específicas de limpieza y validación sobre las observaciones identificadas durante la auditoría.

3. PROCESS

3.1 Creación del conjunto de datos limpio

Antes de realizar cualquier proceso de limpieza, se decidió conservar el conjunto de datos original sin modificaciones y generar una nueva tabla denominada **Data_Clean**, la cual será utilizada durante las etapas posteriores del proyecto.

Esta decisión permite preservar la integridad de los datos originales, facilita la reproducibilidad del proceso de limpieza y proporciona un respaldo en caso de ser necesario comparar los datos antes y después de las transformaciones realizadas.

3.2 Eliminación de registros duplicados

Con base en los resultados obtenidos durante la fase **PREPARE**, se identificaron **165 grupos de registros completamente duplicados**, es decir, observaciones con valores idénticos en todas las variables del conjunto de datos.

Dado que no existe evidencia de que dichos registros representen eventos distintos del negocio, se determinó que corresponden a duplicados generados durante la captura o almacenamiento de la información. Por ello, se decidió eliminar las copias redundantes y conservar únicamente un registro por cada grupo duplicado.

Para realizar este procedimiento se utilizó la instrucción **SELECT DISTINCT**, la cual permite conservar únicamente las combinaciones únicas de valores presentes en la tabla original. El resultado del proceso se almacenó en la nueva tabla **Data_Clean**, preservando intacto el conjunto de datos original.

Como resultado de esta transformación, el número de registros pasó de **32,581** a **32,416**, confirmando la eliminación de **165 registros duplicados** sin pérdida de información única.

Concepto	Registros
Registros originales	32,581
Registros después de la limpieza	32,416
Registros eliminados	165

3.3 Evaluación de valores nulos en loan_int_rate

Durante la fase **PREPARE** se identificaron valores nulos en la variable **loan_int_rate**, correspondiente a la tasa de interés del préstamo. Debido a que esta variable es relevante para el análisis de riesgo crediticio y para la interpretación de las condiciones financieras de cada préstamo, se decidió no eliminar automáticamente los registros afectados, ya que esto implicaría la pérdida de información potencialmente valiosa.

Como primer paso, se analizó el comportamiento de la tasa de interés según la variable **loan_grade**, con el objetivo de determinar si existía una relación entre ambas variables y evaluar la viabilidad de realizar una imputación por categoría.

Los resultados mostraron un patrón consistente, observándose un incremento progresivo de la tasa de interés conforme aumenta el grado de riesgo del préstamo.

loan_grade	Tasa promedio
A	7.33%
B	11.00%
C	13.46%
D	15.36%
E	17.01%
F	18.61%
G	20.25%

Este comportamiento indica que la tasa de interés depende del **loan_grade**, por lo que utilizar un único promedio para todos los registros podría distorsionar los valores imputados y alterar la relación existente entre ambas variables.

Posteriormente, se analizó la distribución de los valores nulos dentro de cada categoría de **loan_grade**.

loan_grade	Porcentaje de valores nulos
F	11.20%
B	10.11%
C	9.77%
A	9.25%
E	8.62%
D	8.59%
G	7.81%

Se observó que los valores faltantes se encuentran distribuidos entre todas las categorías, sin concentrarse de manera desproporcionada en un grado específico. Esto sugiere que la ausencia de información no está asociada exclusivamente a un nivel de riesgo determinado, por lo que se consideró como estrategia preliminar imputar los valores nulos utilizando una medida calculada de forma independiente para cada **loan_grade**.

Como parte de la validación de dicha estrategia, se comparó el **promedio** y la **mediana** de la tasa de interés dentro de cada categoría, con el propósito de identificar posibles sesgos o la presencia de valores atípicos que pudieran afectar la representatividad del promedio.

loan_grade	Promedio (%)	Mediana (%)
A	7.33	7.49
B	11.00	10.99
C	13.46	13.48
D	15.36	15.31
E	17.01	16.82
F	18.61	18.53
G	20.25	20.16

Los resultados muestran diferencias mínimas entre ambas medidas de tendencia central en todos los grados de préstamo, lo que indica que la distribución de la tasa de interés es relativamente estable y no presenta evidencia de valores extremos que afecten significativamente el promedio.

Con base en este análisis, se determinó que **el promedio calculado para cada categoría de loan_grade** constituye una medida representativa para imputar los valores faltantes de **loan_int_rate**, ya que permite conservar las características propias de cada nivel de riesgo sin introducir sesgos relevantes en el conjunto de datos.

3.4 Tratamiento de edades atípicas en person_age

Durante la fase **PREPARE** se identificaron valores atípicos en la variable **person_age**, correspondiente a la edad del solicitante. La revisión inicial mostró una edad máxima de **144 años**, por lo que se realizó un análisis adicional para determinar la cantidad de registros afectados y evaluar su consistencia.

Se identificaron cinco observaciones con edades superiores a 100 años:

Edad	Total de registros
------	--------------------

144	3
-----	---

123	2
-----	---

Posteriormente, se revisó la información completa de estos registros con el objetivo de determinar si era posible corregir la edad mediante otras variables del conjunto de datos. Aunque algunos campos asociados, como el ingreso, la antigüedad laboral y el monto del préstamo, podrían corresponder a valores válidos de forma aislada, no existe información suficiente para inferir con certeza la edad real de los solicitantes.

Debido a que **person_age** es una variable relevante para el análisis de riesgo crediticio, conservar edades de 123 y 144 años podría distorsionar indicadores descriptivos como el promedio, el valor máximo y la distribución general de edades. Asimismo, reemplazarlas mediante la media o la mediana introduciría valores artificiales sin una base confiable.

Considerando que estos registros representan únicamente **5 observaciones de un total de 32,416**, equivalente aproximadamente al **0.015%** del conjunto de datos, se decidió eliminarlos de la tabla procesada.

Como resultado de esta transformación, el número de registros pasó de **32,416 a 32,411**, eliminándose exclusivamente las observaciones con edades consideradas inconsistentes.

3.5 Evaluación y tratamiento de **person_emp_length**

Durante la fase **PREPARE** se identificaron anomalías en la variable **person_emp_length**, correspondiente a la antigüedad laboral del solicitante. La revisión inicial mostró un valor máximo de **123 años**, lo cual resulta inconsistente dentro del contexto del conjunto de datos.

Como primer paso, se evaluó la presencia de valores faltantes en esta variable. Se identificaron **887 registros nulos**, equivalentes al **2.74%** del conjunto de datos después de la eliminación de duplicados y edades inconsistentes.

A diferencia de **loan_int_rate**, no se identificó una relación suficientemente directa y estable con otra variable que permitiera realizar una imputación confiable. La antigüedad laboral depende de múltiples factores individuales, como la edad de incorporación al

mercado laboral, los periodos de desempleo, los cambios de empleo y las interrupciones en la vida profesional.

Por esta razón, se decidió **conservar los valores nulos**, ya que reemplazarlos mediante el promedio o la mediana introduciría información artificial sin una base suficientemente sólida. En los análisis posteriores donde la antigüedad laboral sea una variable de interés, se considerarán únicamente los registros con información disponible.

Posteriormente, se evaluó la consistencia lógica entre **person_emp_length** y **person_age**. Se identificaron dos registros donde la antigüedad laboral era superior a la edad del solicitante:

Edad	Antigüedad laboral
------	--------------------

21	123
----	-----

22	123
----	-----

Estos valores representan una inconsistencia objetiva, ya que una persona no puede tener más años de experiencia laboral que años de vida.

Aunque el resto de las variables asociadas a dichos registros no presentó anomalías evidentes, no fue posible inferir con certeza la antigüedad laboral correcta. Debido a que conservar estos valores podría distorsionar el máximo, el rango y la distribución de la variable, se decidió eliminar únicamente estos dos registros.

La eliminación se realizó conservando tanto los valores válidos como los registros con **person_emp_length nulo**, evitando descartar información adicional de manera involuntaria.

Como resultado de esta transformación, el conjunto de datos pasó de **32,411 a 32,409 registros**, eliminándose exclusivamente las dos observaciones con antigüedad laboral inconsistente.

3.6 Evaluación de valores atípicos en person_income

Durante la fase **PREPARE** se identificaron valores elevados en la variable **person_income**, correspondiente al ingreso anual del solicitante. Debido a que esta variable puede influir en la evaluación del riesgo crediticio, se realizó un análisis para determinar si dichos valores representaban errores de captura o simplemente observaciones extremas dentro de la distribución.

Como primer paso, se calcularon las principales medidas de tendencia central y dispersión.

Métrica	Valor
Mínimo	4,000
Máximo	2,039,784
Promedio (Media)	65,894.28
Mediana	55,000

Posteriormente, se inspeccionaron los registros con los ingresos más altos del conjunto de datos. Aunque se identificaron valores considerablemente superiores al promedio, no se observaron inconsistencias adicionales en variables relacionadas como la edad, la antigüedad laboral, la clasificación del préstamo o el tipo de propiedad de la vivienda.

Asimismo, la comparación entre la **media** y la **mediana** mostró una diferencia moderada, indicando una distribución sesgada hacia la derecha, comportamiento esperado en variables económicas como el ingreso anual. La presencia de personas con ingresos elevados incrementa la media, mientras que la mediana permanece representativa del comportamiento central de la población.

Con base en este análisis, se concluye que los valores elevados corresponden a **valores atípicos (outliers) plausibles**, pero no existe evidencia suficiente para clasificarlos como errores de captura. En consecuencia, **no se realizó ninguna transformación sobre la variable person_income**, preservando la variabilidad natural del conjunto de datos y evitando eliminar observaciones potencialmente válidas.

3.7 Conclusión de la fase PROCESS

Al finalizar la fase PROCESS, el conjunto de datos fue sometido a un proceso de limpieza y validación con el objetivo de garantizar la calidad de la información antes de iniciar el análisis exploratorio.

Durante esta etapa se eliminaron registros duplicados, se imputaron los valores faltantes de `loan_int_rate` utilizando el promedio correspondiente a cada `loan_grande`, se eliminaron registros con edades inconsistentes superiores a 100 años y se removieron únicamente dos observaciones cuya antigüedad laboral era mayor que la edad del solicitante.

Por otra parte, se decidió conservar los valores nulos de `person_emp_length`, ya que no existía una base estadística suficiente para realizar una imputación confiable sin introducir información artificial. Asimismo, los valores elevados de `person_income` fueron analizados y clasificados como valores atípicos plausibles, por lo que se mantuvieron sin modificaciones.

Como resultado de este proceso, se obtuvo un conjunto de datos con 32,409 registros, consistente y preparado para la fase de análisis, asegurando que las transformaciones aplicadas se fundamentaran en criterios estadísticos y de calidad de datos, y no únicamente en la eliminación sistemática de observaciones.

4. ANÁLISIS

4.1 Introducción

Con el conjunto de datos previamente preparado y validado durante la fase **PROCESS**, se inició el análisis exploratorio con el objetivo de identificar patrones, tendencias y relaciones entre las variables que influyen en el riesgo crediticio de los solicitantes.

En esta etapa se utilizaron consultas SQL para responder las preguntas de negocio definidas durante la fase **ASK**, explorando el comportamiento de las características demográficas, financieras y crediticias de los clientes, así como su relación con el estado final del préstamo (**loan_status**).

Los resultados obtenidos servirán como base para el desarrollo del dashboard en Power BI y para la formulación de recomendaciones orientadas a mejorar la evaluación del riesgo crediticio.

4.2 Preguntas del Negocio

Antes de iniciar el análisis, se retomaron las preguntas de negocio definidas al comienzo del proyecto:

1. ¿Cuál es la tasa general de incumplimiento de los préstamos?
2. ¿Qué propósito de préstamo presenta el mayor riesgo de incumplimiento?
3. ¿Cómo influye la clasificación del préstamo (**loan_grade**) en la probabilidad de incumplimiento?
4. ¿Existe relación entre la tasa de interés y el incumplimiento del préstamo?
5. ¿Cómo influye el ingreso anual del solicitante en el riesgo crediticio?
6. ¿La propiedad de la vivienda (**person_home_ownership**) tiene relación con el incumplimiento?
7. ¿Qué características presentan los solicitantes con mayor riesgo de impago?

4.2.1 Estructura del análisis

Con el fin de responder las preguntas de negocio planteadas durante la fase **ASK**, el análisis se desarrollará en el siguiente orden:

1. **Análisis general del portafolio de préstamos**
 - Distribución general de los préstamos.
 - Tasa de incumplimiento.
 - Indicadores generales del conjunto de datos.
2. **Análisis del propósito del préstamo**
 - Riesgo de incumplimiento según el destino del préstamo.
3. **Análisis de la clasificación del préstamo**
 - Relación entre **loan_grade** y el riesgo crediticio.

4. **Análisis de la tasa de interés**
 - Comportamiento de `loan_int_rate` y su relación con el incumplimiento.
5. **Análisis del ingreso anual**
 - Influencia de `person_income` sobre el riesgo del préstamo.
6. **Análisis del tipo de propiedad de vivienda**
 - Relación entre `person_home_ownership` y el incumplimiento.
7. **Análisis del historial crediticio**
 - Influencia de `cb_person_cred_hist_length` sobre el riesgo crediticio.
8. **Perfil de riesgo del solicitante**
 - Identificación de las características comunes de los solicitantes con mayor probabilidad de incumplimiento.

4.3 Análisis general del portafolio de préstamos

4.3.1 Objetivo

El primer paso del análisis consiste en comprender la composición general del portafolio de préstamos. Para ello, se calcularán indicadores descriptivos que permitan conocer el tamaño del conjunto de datos y la proporción de préstamos que presentan incumplimiento, estableciendo así un punto de partida para los análisis posteriores.

4.3.2 Resultados

Indicador	Valor
Total de préstamos	32,409
Préstamos pagados	25,321
Préstamos en incumplimiento	7,088
Tasa de incumplimiento	21.87%
Monto total prestado	310,882,900
Monto promedio del préstamo	9,592.49

4.3.3 Análisis

El conjunto de datos está conformado por **32,409 préstamos**, de los cuales **7,088** registraron incumplimiento, lo que representa una **tasa general de incumplimiento del 21.87%**.

En términos generales, aproximadamente **uno de cada cinco préstamos** termina en incumplimiento, lo que convierte esta métrica en el punto de referencia para el resto del análisis.

Asimismo, el monto total otorgado supera los **310 millones**, mientras que el préstamo promedio asciende a **9,592.49**, lo que indica que la mayoría de los créditos corresponden a montos relativamente moderados.

La tasa general de incumplimiento servirá como **línea base** para comparar el comportamiento de las diferentes variables analizadas en las siguientes secciones, permitiendo identificar aquellos segmentos cuyo riesgo se encuentra por encima o por debajo del promedio del portafolio.

4.3.4 Conclusión

El portafolio presenta una tasa general de incumplimiento del **21.87%**, estableciendo el punto de referencia para evaluar el riesgo asociado a las distintas características de los solicitantes y de los préstamos. A partir de este indicador se analizará si variables como el propósito del préstamo, la clasificación crediticia, el ingreso anual o el historial crediticio presentan comportamientos significativamente diferentes respecto al promedio del conjunto de datos.

4.4 Análisis del propósito del préstamo

4.4.1 Objetivo

Analizar la relación entre el propósito del préstamo (`loan_intent`) y la tasa de incumplimiento, con el fin de identificar cuáles categorías representan un mayor riesgo para la institución financiera y comprender cómo varía el comportamiento de pago según el destino del crédito.

4.4.2 Resultados

El análisis del propósito del préstamo mostró los siguientes indicadores:

Propósito del préstamo	Total de préstamos	Incumplimientos	Tasa de incumplimiento	Monto promedio
Debt Consolidation	5,189	1,488	28.68%	9,605.27
Medical	6,042	1,617	26.76%	9,271.58
Home Improvement	3,594	940	26.15%	10,362.12
Personal	5,496	1,093	19.89%	9,575.89
Education	6,409	1,106	17.26%	9,478.89
Venture	5,679	844	14.86%	9,579.42

4.4.3 Análisis

Los resultados evidencian que el propósito del préstamo influye significativamente en el comportamiento de pago de los solicitantes.

Los préstamos destinados a **Debt Consolidation** presentan la mayor tasa de incumplimiento (**28.68%**), superando en casi **7 puntos porcentuales** la tasa general del portafolio (**21.87%**). De forma similar, las categorías **Medical** (**26.76%**) y **Home Improvement** (**26.15%**) también muestran niveles de riesgo superiores al promedio.

En contraste, los préstamos solicitados para **Venture** registran la menor tasa de incumplimiento (**14.86%**), seguidos por **Education** (**17.26%**), lo que sugiere un comportamiento de pago considerablemente más favorable.

Por otra parte, el monto promedio del préstamo presenta diferencias relativamente pequeñas entre las distintas categorías, por lo que no parece ser el principal factor que explica las variaciones observadas en las tasas de incumplimiento. Esto indica que el **propósito del préstamo** tiene un mayor poder explicativo sobre el riesgo crediticio que el monto promedio otorgado.

4.4.4 Conclusión

El propósito del préstamo constituye un factor relevante en la evaluación del riesgo crediticio. Los préstamos destinados a **consolidación de deudas, gastos médicos y mejoras del hogar** presentan una probabilidad de incumplimiento superior al promedio del portafolio, mientras que aquellos destinados a **emprendimientos y educación** muestran un comportamiento de pago más favorable.

Estos resultados sugieren que el destino del crédito puede utilizarse como una variable de apoyo en los modelos de evaluación del riesgo y en la definición de estrategias de otorgamiento de préstamos.

4.5 Análisis de la clasificación del préstamo

4.5.1 Objetivo

Analizar la relación entre la clasificación del préstamo (loan_grade) y la tasa de incumplimiento, con el objetivo de evaluar si la calificación asignada refleja adecuadamente el nivel de riesgo crediticio de los solicitantes.

4.5.2 Resultados

Grado	Total préstamos	Incumplimientos	Tasa de incumplimiento	Monto promedio
A	10,702	1,066	9.96%	8,544.63
B	10,384	1,695	16.32%	9,990.65
C	6,436	1,336	20.76%	9,220.52
D	3,619	2,137	59.05%	10,849.09
E	963	621	64.49%	12,919.91
F	241	170	70.54%	14,717.32
G	64	63	98.44%	17,195.70

4.5.3 Análisis

La clasificación del préstamo (loan_grade) presenta una relación directa con la probabilidad de incumplimiento. Conforme la calificación disminuye de **A** hacia **G**, la tasa de incumplimiento aumenta de manera consistente.

Los préstamos clasificados como **A** registran la menor tasa de incumplimiento (**9.96%**), mientras que los grados **B** (**16.32%**) y **C** (**20.76%**) mantienen niveles de riesgo relativamente bajos y cercanos a la tasa general del portafolio (**21.87%**).

Sin embargo, a partir del **grado D** se observa un incremento considerable en el riesgo crediticio. La tasa de incumplimiento aumenta hasta **59.05%**, y continúa incrementándose en los grados **E** (**64.49%**), **F** (**70.54%**) y **G** (**98.44%**).

Además, se observa una tendencia creciente en el monto promedio del préstamo conforme empeora la clasificación crediticia, pasando de **8,544.63** en el grado **A** a **17,195.70** en el grado **G**. Esto indica que los préstamos de mayor riesgo también tienden a otorgarse por montos más elevados dentro del conjunto de datos.

4.5.4 Conclusión

La clasificación del préstamo constituye uno de los principales indicadores del riesgo crediticio dentro del conjunto de datos. Los resultados muestran una relación clara entre el deterioro de la calificación y el incremento en la tasa de incumplimiento, validando la utilidad de loan_grade como una variable altamente predictiva del comportamiento de pago.

El cambio observado entre los grados **C** y **D** representa el punto donde el riesgo de incumplimiento aumenta de manera significativa, por lo que esta clasificación podría utilizarse como un criterio relevante para fortalecer los procesos de evaluación y aprobación de préstamos.

4.6 Análisis de la tasa de interés

4.6.1 Objetivo

Analizar la relación entre la tasa de interés del préstamo (loan_int_rate) y la tasa de incumplimiento, con el fin de identificar si préstamos con tasas de interés más elevadas presentan un mayor riesgo crediticio.

4.6.2 Resultados

Rango de tasa de interés	Total préstamos	Incumplimientos	Tasa de incumplimiento	Monto promedio
5–8%	8,706	819	9.41%	8,548.90
8–11%	8,156	1,247	15.29%	9,530.76
11–14%	9,564	1,882	19.68%	9,763.73
14–17%	5,027	2,494	49.61%	10,395.13
17–20%	877	578	65.91%	13,659.61
20% +	79	68	86.08%	14,015.51

4.6.3 Análisis

La tasa de interés muestra una relación positiva con la probabilidad de incumplimiento. Conforme aumenta el porcentaje de interés aplicado al préstamo, también se incrementa la tasa de incumplimiento.

Los préstamos con tasas entre **5% y 14%** presentan niveles de incumplimiento inferiores o cercanos al promedio general del portafolio (**21.87%**). Sin embargo, a partir del rango **14–17%** se observa un incremento considerable en el riesgo, alcanzando una tasa de incumplimiento del **49.61%**.

Esta tendencia continúa en los rangos superiores, donde los préstamos con tasas entre **17% y 20%** registran una tasa de incumplimiento del **65.91%**, mientras que aquellos con tasas iguales o superiores al **20%** alcanzan un **86.08%** de incumplimiento.

Asimismo, el monto promedio del préstamo aumenta conforme se incrementa la tasa de interés, lo que sugiere que los créditos con mayor costo financiero también tienden a otorgarse por montos más elevados.

4.6.4 Conclusión

La tasa de interés constituye un indicador relevante del riesgo crediticio dentro del conjunto de datos. Los resultados muestran que el riesgo de incumplimiento aumenta progresivamente conforme se incrementa la tasa de interés, observándose un cambio significativo a partir de tasas superiores al **14%**.

Este comportamiento sugiere que la tasa de interés no solo refleja el costo del financiamiento, sino también el nivel de riesgo asociado al solicitante. En consecuencia, esta variable representa un elemento clave para el análisis del riesgo crediticio y para el desarrollo de modelos predictivos de incumplimiento.

4.7 Análisis del ingreso anual

4.7.1 Objetivo

Analizar la relación entre el ingreso anual del solicitante (*person_income*) y la tasa de incumplimiento, con el propósito de determinar si el nivel de ingresos está asociado con el riesgo crediticio.

4.7.2 Resultados

Para segmentar los niveles de ingreso se utilizaron cuartiles, obteniendo los siguientes puntos de corte:

- Q1: hasta **\$38,450**
- Q2: de **\$38,450 a \$55,000**
- Q3: de **\$55,000 a \$78,300**
- Q4: más de **\$78,300**

Los resultados fueron:

Segmento	Total préstamos	Pagados	Incumplidos	Tasa de incumplimiento
Q1 – Low Income	8,080	4,864	3,216	39.80%
Q2 – Lower-Middle Income	8,212	6,454	1,758	21.41%

Q3 – Upper-Middle Income	7,887	6,542	1,345	17.05%
Q4 – High Income	8,230	7,461	769	9.34%

4.7.3 Análisis

Los resultados muestran una relación inversa entre el nivel de ingreso y la tasa de incumplimiento. El segmento de menores ingresos (Q1) presenta la mayor tasa de incumplimiento, con **39.80%**, mientras que esta disminuye progresivamente conforme aumenta el nivel de ingreso.

Q2 registra una tasa de **21.41%**, Q3 de **17.05%** y Q4 únicamente de **9.34%**. En consecuencia, la tasa de incumplimiento observada en Q1 es aproximadamente **4.3 veces mayor** que la registrada en Q4.

La tendencia consistente entre los cuatro segmentos indica que `person_income` presenta una asociación relevante con el comportamiento de pago dentro del portafolio analizado.

4.7.4 Conclusión

El ingreso anual del solicitante presenta una asociación relevante con el riesgo crediticio. Los solicitantes pertenecientes a los segmentos de menores ingresos registran mayores tasas de incumplimiento, mientras que los segmentos de mayores ingresos presentan niveles considerablemente menores.

Sin embargo, esta relación debe interpretarse como una **asociación y no como causalidad**, por lo que el ingreso debe evaluarse en conjunto con otras características financieras y crediticias del solicitante.

4.8 Análisis de la proporción préstamo-ingreso

4.8.1 Objetivo

Analizar la relación entre la proporción que representa el préstamo respecto al ingreso del solicitante (`loan_percent_income`) y la tasa de incumplimiento, con el propósito de determinar si una mayor carga relativa del préstamo está asociada con un mayor riesgo crediticio.

4.8.2 Resultados

La distribución de `loan_percent_income` presentó un valor mínimo de **0%**, un máximo de **83%** y un promedio de **17%**.

Para realizar una comparación equilibrada, los registros fueron inicialmente segmentados mediante cuartiles:

Segmento	Rango	Total préstamos	Pagados	Incumplidos	Default rate
Q1	$\leq 9\%$	8,904	7,872	1,032	11.59%
Q2	$>9\% - 15\%$	8,182	7,133	1,049	12.82%
Q3	$>15\% - 23\%$	7,671	6,240	1,431	18.65%
Q4	$>23\%$	7,652	4,076	3,576	46.73%

Debido al fuerte incremento observado en Q4, se realizó un análisis adicional sobre los registros con `loan_percent_income > 0.23`.

Rango	Total préstamos	Pagados	Incumplidos	Default rate
$>23\% - 30\%$	3,834	2,947	887	23.14%
$>30\% - 40\%$	2,700	840	1,860	68.89%
$>40\% - 50\%$	872	236	636	72.94%

>50%	246	53	193	78.46%
------	-----	----	-----	---------------

4.8.3 Análisis

Los resultados muestran una asociación positiva entre `loan_percent_income` y la tasa de incumplimiento. Los primeros dos cuartiles presentan tasas relativamente similares, de **11.59%** y **12.82%**, mientras que Q3 aumenta a **18.65%**.

El cambio más significativo se observa en Q4, donde la tasa de incumplimiento alcanza **46.73%**, considerablemente por encima de los demás segmentos.

Debido a esta diferencia, se profundizó el análisis dentro de Q4. Los préstamos cuya proporción respecto al ingreso se encuentra entre **23% y 30%** presentan una tasa de incumplimiento de **23.14%**. Sin embargo, en el segmento superior al 30% la tasa aumenta considerablemente: **68.89%** entre 30% y 40%, **72.94%** entre 40% y 50%, y **78.46%** por encima del 50%.

El incremento de **23.14% a 68.89%** representa una diferencia de **45.75 puntos porcentuales**, lo que indica una marcada concentración del riesgo entre los préstamos cuya proporción respecto al ingreso supera aproximadamente el 30%.

4.8.4 Conclusión

`loan_percent_income` presenta una asociación relevante con el riesgo de incumplimiento. En particular, los resultados muestran una concentración considerable del riesgo en los préstamos que representan más del **30% del ingreso del solicitante**.

Este resultado complementa el análisis previo de `person_income`, ya que sugiere que no solo el nivel absoluto de ingresos está asociado con el comportamiento de pago, sino también el tamaño del préstamo en relación con la capacidad económica del solicitante.

Sin embargo, el umbral del 30% debe interpretarse como un **hallazgo observado en este conjunto de datos y no como un límite crediticio universal o causal**. Su relevancia debe evaluarse junto con otras variables de riesgo antes de utilizarlo como criterio para la toma de decisiones.

4.9 Análisis por situación de vivienda

4.9.1 Objetivo

Analizar la relación entre la situación de vivienda del solicitante (`person_home_ownership`) y la tasa de incumplimiento, con el propósito de identificar diferencias en el riesgo crediticio entre los distintos segmentos y evaluar su participación dentro del portafolio de préstamos.

4.9.2 Resultados

Los solicitantes fueron agrupados según las categorías existentes en `person_home_ownership`. Además de la tasa de incumplimiento, se calculó la participación de cada segmento sobre el total de préstamos (`portfolio_share`).

Situación de vivienda	Total préstamos	Participación del portafolio	Pagados	Incumplidos	Default rate
OWN	2,563	7.91%	2,371	192	7.49%
MORTGAGE	13,366	41.24%	11,679	1,687	12.62%
OTHER	106	0.33%	73	33	31.13%
RENT	16,374	50.52%	11,198	5,176	31.61%

4.9.3 Análisis

Los resultados muestran diferencias relevantes en la tasa de incumplimiento según la situación de vivienda.

Los solicitantes con vivienda propia (OWN) presentan la menor tasa de incumplimiento, con **7.49%**, seguidos por aquellos con hipoteca (MORTGAGE), con **12.62%**. En contraste, los solicitantes que rentan (RENT) presentan una tasa considerablemente superior de **31.61%**, aproximadamente **4.2 veces** la observada en el segmento OWN.

El segmento RENT resulta especialmente relevante desde la perspectiva del portafolio, ya que además de presentar una elevada tasa de incumplimiento, representa **50.52% del total**

de préstamos analizados. Por su parte, MORTGAGE concentra otro **41.24%** del portafolio, pero presenta una tasa de incumplimiento considerablemente menor.

Aunque OTHER registra una tasa elevada de **31.13%**, representa únicamente **0.33% del portafolio**, por lo que el reducido número de observaciones limita su relevancia comparativa.

4.9.4 Conclusión

La situación de vivienda presenta una asociación relevante con el comportamiento de pago. El segmento RENT destaca por combinar una **alta tasa de incumplimiento (31.61%)** con la **mayor participación dentro del portafolio (50.52%)**, convirtiéndolo en un segmento relevante para el análisis del riesgo crediticio.

Sin embargo, la situación de vivienda no debe interpretarse como una causa directa del incumplimiento. Su relación con el riesgo puede estar asociada con otras características financieras del solicitante, como el nivel de ingresos, la carga del préstamo y su perfil crediticio.

4.10 Análisis de antecedentes de incumplimiento

4.10.1 Objetivo

Analizar la relación entre los antecedentes de incumplimiento del solicitante (`cb_person_default_on_file`) y el incumplimiento del préstamo actual, evaluando tanto la tasa de default de cada segmento como su participación dentro del portafolio y su contribución al total de incumplimientos.

4.10.2 Resultados

Los solicitantes fueron clasificados según la existencia de antecedentes de incumplimiento registrados en su historial crediticio.

Default previo	Total préstamos	Portfolio share	Pagados	Incumplidos	Default share	Default rate
false	26,680	82.32%	21,761	4,919	69.40%	18.44%
true	5,729	17.68%	3,560	2,169	30.60%	37.86%

4.10.3 Análisis

Los resultados muestran una asociación clara entre los antecedentes de incumplimiento y el riesgo del préstamo actual.

Los solicitantes con antecedentes (`true`) presentan una tasa de incumplimiento de **37.86%**, frente a **18.44%** entre quienes no cuentan con antecedentes (`false`). Por lo tanto, la tasa de default del grupo con antecedentes es aproximadamente **2.05 veces mayor**.

Además, existe una diferencia relevante entre la participación del segmento dentro del portafolio y su contribución a los incumplimientos. Los solicitantes con antecedentes representan únicamente **17.68% de los préstamos**, pero concentran **30.60% de todos los defaults**, lo que indica una participación desproporcionadamente alta en los incumplimientos respecto a su peso en el portafolio.

Sin embargo, el segmento sin antecedentes también presenta un hallazgo importante. Aunque su tasa de incumplimiento individual es menor (**18.44%**), representa **82.32% del portafolio** y, debido a su mayor tamaño, concentra **69.40% de todos los incumplimientos**, equivalentes a 4,919 préstamos.

Esto demuestra la diferencia entre **riesgo relativo del segmento y contribución al riesgo total del portafolio**: el grupo con antecedentes presenta mayor probabilidad de incumplimiento, mientras que el grupo sin antecedentes genera la mayoría de los defaults en términos absolutos debido a su elevada exposición.

4.10.4 Conclusión

Los antecedentes de incumplimiento constituyen un indicador relevante de riesgo crediticio, ya que los solicitantes con historial de default presentan una tasa de incumplimiento actual aproximadamente **dos veces superior** a la de aquellos sin antecedentes.

No obstante, enfocarse exclusivamente en solicitantes con antecedentes no permitiría identificar la mayor parte de los incumplimientos del portafolio. A pesar de presentar menor riesgo relativo, los solicitantes sin antecedentes generan **69.40% de los defaults totales** debido a que representan la gran mayoría de los préstamos analizados.

Por lo tanto, `cb_person_default_on_file` puede considerarse una variable relevante para la segmentación del riesgo, pero debe analizarse en combinación con otros factores crediticios para identificar adecuadamente el riesgo dentro del segmento mayoritario de clientes sin antecedentes.

4.11 Análisis de la edad del solicitante

4.11.1 Objetivo

Analizar la relación entre la edad del solicitante (person_age) y la tasa de incumplimiento, con el propósito de determinar si existen diferencias relevantes en el riesgo crediticio entre distintos grupos de edad.

4.11.2 Resultados

La variable person_age presenta un rango entre **20 y 94 años**, con una edad promedio de **27.73 años**. Los cuartiles muestran una fuerte concentración de solicitantes jóvenes, con Q1 en 23 años, mediana en 26 años y Q3 en 30 años.

Debido a esta concentración, se decidió utilizar rangos de edad interpretables en lugar de cuartiles.

Edad	Total préstamos	Portfolio share	Pagos	Incumplidos	Default share	Default rate
20–24	12,220	37.71%	9,368	2,852	40.24%	23.34%
25–29	11,142	34.38%	8,756	2,386	33.66%	21.41%
30–39	7,291	22.50%	5,815	1,476	20.82%	20.24%
40–49	1,421	4.38%	1,132	289	4.08%	20.34%
50+	335	1.03%	250	85	1.20%	25.37%

4.11.3 Análisis

Los resultados no muestran diferencias significativas en la tasa de incumplimiento entre los principales grupos de edad.

Entre los solicitantes de **20 a 49 años**, el `default_rate` permanece dentro de un rango relativamente estrecho de **20.24% a 23.34%**, lo que indica que la edad, considerada de forma aislada, no presenta una asociación especialmente fuerte con el incumplimiento.

Los solicitantes de 20 a 24 años concentran **40.24% de todos los defaults**, pero también representan **37.71% del portafolio**, por lo que su mayor contribución al total de incumplimientos se explica principalmente por su elevada participación dentro de la muestra y no por una tasa de default considerablemente superior.

El grupo de 50 años o más presenta una tasa de incumplimiento de **25.37%**; sin embargo, representa únicamente **1.03% del portafolio**, por lo que el reducido número de observaciones limita la relevancia de esta diferencia.

4.11.4 Conclusión

La edad del solicitante no presenta una asociación individual fuerte con el riesgo de incumplimiento dentro del conjunto de datos analizado.

Aunque los grupos más jóvenes concentran una mayor cantidad de defaults, esto se encuentra principalmente relacionado con su mayor representación dentro del portafolio. Las tasas de incumplimiento permanecen relativamente estables entre los principales grupos de edad.

Por lo tanto, `person_age` puede considerarse una variable de **baja relevancia individual** para explicar el incumplimiento y debería utilizarse, en todo caso, en combinación con otros factores financieros y crediticios.

4.12 Análisis de la antigüedad laboral

4.12.1 Objetivo

Analizar la relación entre la antigüedad laboral del solicitante (`person_emp_length`) y la tasa de incumplimiento, con el propósito de determinar si una mayor estabilidad laboral está asociada con un menor riesgo crediticio.

4.12.2 Resultados

La variable `person_emp_length` presenta un valor mínimo de **0 años**, un máximo de **41 años** y un promedio de **4.78 años**. Los cuartiles se ubicaron en 2, 4 y 7 años, por lo que se utilizaron estos puntos como referencia para segmentar la antigüedad laboral.

Antigüedad laboral	Total préstamos	Portfolio share	Pagos	Incumplidos	Default share	Default rate
0–2 años	10,814	34.31%	7,881	2,933	43.09%	27.12%
3–4 años	6,303	20.00%	5,000	1,303	19.14%	20.67%
5–7 años	7,763	24.63%	6,306	1,457	21.40%	18.77%
8+ años	6,642	21.07%	5,528	1,114	16.37%	16.77%

4.12.3 Análisis

Los resultados muestran una relación inversa entre la antigüedad laboral y la tasa de incumplimiento.

Los solicitantes con **0 a 2 años de antigüedad laboral** presentan la mayor tasa de default, con **27.12%**. Conforme aumenta la antigüedad, la tasa disminuye progresivamente a **20.67%** para 3–4 años, **18.77%** para 5–7 años y **16.77%** para solicitantes con 8 años o más.

El segmento de menor antigüedad también presenta una concentración desproporcionada de incumplimientos. Aunque representa **34.31% del portafolio**, genera **43.09% de todos los defaults**.

En contraste, el grupo con 8 años o más de antigüedad representa **21.07% del portafolio**, pero únicamente **16.37% de los incumplimientos totales**.

La tasa de default de los solicitantes con 0–2 años de antigüedad es aproximadamente **1.62 veces mayor** que la observada entre quienes cuentan con 8 años o más de experiencia laboral.

4.12.4 Conclusión

La antigüedad laboral presenta una asociación relevante con el comportamiento de pago. Los solicitantes con menor estabilidad laboral registran tasas de incumplimiento superiores, mientras que una mayor antigüedad se encuentra asociada con menores niveles de default.

Por lo tanto, `person_emp_length` puede considerarse una variable útil para la segmentación del riesgo crediticio, aunque debe evaluarse en conjunto con otras características financieras y crediticias del solicitante.

4.13 Análisis del monto del préstamo

4.13.1 Objetivo

Analizar la relación entre el monto del préstamo (`loan_amnt`) y la tasa de incumplimiento, con el propósito de determinar si los préstamos de mayor monto presentan un mayor nivel de riesgo crediticio.

4.13.2 Resultados

La variable `loan_amnt` presenta un valor mínimo de **\$500**, un máximo de **\$35,000** y un promedio de **\$9,592.49**. Los cuartiles se ubicaron en **\$5,000**, **\$8,000** y **\$12,075**, los cuales fueron utilizados para segmentar los préstamos por monto.

Segmento	Rango	Total préstamos	Portfolio share	Pagados	Incumplidos	Default share	Default rate
Q1	≤ \$5,000	9,428	29.09%	7,498	1,930	27.23%	20.00%
Q2	\$5,001 –\$8,000	7,281	22.47%	6,065	1,216	17.16%	17.00%
Q3	\$8,001 –\$12,075	7,573	23.37%	6,054	1,519	21.43%	20.00%
Q4	> \$12,075	8,127	25.08%	5,704	2,423	34.18%	30.00%

4.13.3 Análisis

Los resultados **no muestran una relación progresiva entre el monto del préstamo y la tasa de incumplimiento**. Los primeros tres segmentos presentan tasas de **20.00%, 17.00% y 20.00%**, respectivamente, por lo que no existe evidencia de un incremento constante del riesgo conforme aumenta el monto.

Sin embargo, el segmento de mayor monto presenta un comportamiento claramente distinto. Los préstamos superiores a **\$12,075** registran una tasa de incumplimiento de **30.00%**, considerablemente superior a la observada en los tres segmentos anteriores.

Este grupo representa **25.08% del portafolio**, pero concentra **34.18% de todos los incumplimientos**, mostrando una sobrerrepresentación dentro de los defaults.

Por lo tanto, los resultados sugieren la existencia de un **efecto concentrado en los préstamos de mayor monto**, más que una relación lineal entre monto e incumplimiento.

No obstante, el monto absoluto del préstamo debe interpretarse junto con la capacidad financiera del solicitante. Una parte del mayor riesgo observado en Q4 podría estar relacionada con la proporción que representa el préstamo respecto al ingreso (`loan_percent_income`).

4.13.4 Conclusión

`loan_amnt` presenta una **relevancia moderada** como indicador individual de riesgo crediticio.

No se observa una tendencia consistente de aumento del incumplimiento conforme aumenta el monto del préstamo. Sin embargo, los préstamos pertenecientes al segmento de mayor monto presentan una tasa de default considerablemente superior.

Por esta razón, no se concluye que un mayor monto por sí solo implique necesariamente mayor riesgo. La relación deberá evaluarse conjuntamente con variables relacionadas con la capacidad de pago, particularmente `loan_percent_income`, durante el análisis multivariable.

5. Análisis combinado de factores de riesgo

5.1 Monto del préstamo vs. proporción del ingreso

5.1.1 Objetivo

Analizar conjuntamente el monto del préstamo (`loan_amnt`) y la proporción que éste representa sobre el ingreso del solicitante (`loan_percent_income`) para determinar si el mayor riesgo observado en préstamos de alto monto se debe al monto absoluto o a la carga financiera relativa del préstamo.

5.1.2 Resultados

Loan Amount	≤9% ingreso	9–15%	15–23%	>23%
Q1 ≤ \$5,000	13%	20%	45%	88%
Q2 \$5,001–\$8,000	7%	12%	20%	44%
Q3 \$8,001–\$12,075	10%	9%	13%	44%
Q4 > \$12,075	9%	10%	14%	46%

5.1.3 Análisis

Al controlar descriptivamente por la proporción del ingreso, el monto absoluto del préstamo no muestra una relación consistente con el incumplimiento.

Por ejemplo, entre los préstamos de mayor monto (Q4), la tasa de default permanece entre **9% y 14%** cuando el préstamo representa hasta 23% del ingreso. Sin embargo, cuando supera el 23% del ingreso, la tasa aumenta hasta **46%**.

El mismo patrón aparece en los demás segmentos de monto. Incluso los préstamos de menor monto presentan tasas elevadas cuando representan una proporción alta del ingreso del solicitante.

El caso más extremo corresponde a préstamos $\leq \$5,000$ que representan más de 23% del ingreso, con una tasa de default de **88%**. Este segmento contiene 321 observaciones, por lo que debe interpretarse con mayor cautela que los grupos de mayor tamaño.

Estos resultados indican que el **tamaño relativo del préstamo respecto al ingreso proporciona una señal de riesgo considerablemente más consistente que el monto absoluto del préstamo**.

5.1.4 Conclusión

El análisis combinado sugiere que el mayor riesgo observado anteriormente entre los préstamos de alto monto no se explica únicamente por `loan_amnt`.

La capacidad de pago relativa, representada por `loan_percent_income`, muestra una asociación mucho más consistente con el incumplimiento. Un préstamo de alto monto puede presentar un riesgo relativamente bajo cuando representa una pequeña proporción del ingreso, mientras que incluso un préstamo pequeño puede presentar un riesgo elevado cuando supone una carga financiera considerable.

Por lo tanto, **loan_percent_income** debe considerarse un indicador de riesgo más relevante que **loan_amnt** de manera aislada.

5.2 Loan Grade vs. Income Burden

5.2.1 Objetivo

Analizar conjuntamente la clasificación crediticia del préstamo (**loan_grade**) y la proporción que representa el préstamo respecto al ingreso del solicitante (**loan_percent_income**) para determinar cómo interactúan ambos factores en el riesgo de incumplimiento.

El objetivo es evaluar si una mayor carga financiera incrementa el riesgo incluso dentro de una misma categoría crediticia y si la combinación de **peor clasificación crediticia + alta carga financiera** permite identificar segmentos especialmente riesgosos.

5.2.2 Resultados

Las tasas de incumplimiento obtenidas fueron:

Loan Grade	Q1 $\leq 9\%$	Q2 9–15%	Q3 15–23%	Q4 $> 23\%$
A	3.81%	3.28%	7.45%	34.50%
B	7.59%	6.75%	10.24%	39.79%
C	10.90%	12.26%	15.68%	46.80%
D	51.10%	53.33%	56.53%	71.05%
E	59.41%	57.75%	54.89%	78.24%
F	59.52%	57.14%	73.68%	79.00%
G	80.00%	100.00%	100.00%	100.00%

5.2.3 Análisis

El análisis combinado muestra que **loan_grade** mantiene una fuerte relación con el incumplimiento incluso al comparar préstamos con niveles similares de carga financiera.

Por ejemplo, dentro del grupo Q1 de **loan_percent_income** ($\leq 9\%$), el **default_rate** aumenta desde **3.81% para Grade A** hasta **51.10% para Grade D** y continúa aumentando en los grados posteriores.

Esto indica que `loan_grade` aporta información relevante sobre el riesgo independientemente de la carga financiera relativa.

Al mismo tiempo, `loan_percent_income` permite diferenciar significativamente el riesgo **dentro de un mismo grade**.

Por ejemplo:

- Grade C: **10.90%** → **12.26%** → **15.68%** → **46.80%**
- Grade D: **51.10%** → **53.33%** → **56.53%** → **71.05%**

La relación no es perfectamente progresiva en todos los grades. Sin embargo, el segmento Q4 (`loan_percent_income > 23%`) presenta generalmente un incremento considerable del incumplimiento.

Un resultado especialmente relevante aparece al comparar perfiles cruzados. Un préstamo **Grade A con una carga superior al 23% del ingreso presenta 34.50% de default**, mientras que un préstamo **Grade C con una carga $\leq 9\%$ presenta únicamente 10.90%**.

Esto demuestra que una buena clasificación crediticia no elimina el riesgo asociado con una carga financiera elevada y que ambas variables proporcionan información complementaria.

Los grades F y especialmente G deben interpretarse con cautela debido al menor número de observaciones. En Grade G, por ejemplo, los cuatro segmentos contienen solamente **5, 10, 16 y 33 préstamos**, respectivamente, por lo que tasas de 80–100% no tienen la misma robustez descriptiva que los resultados observados en grupos con cientos o miles de préstamos.

5.2.4 Conclusión

`loan_grade` y `loan_percent_income` muestran una **fuerte capacidad conjunta para segmentar el riesgo crediticio**.

El deterioro de `loan_grade` está asociado con un incremento considerable en la tasa de incumplimiento, mientras que una elevada proporción del préstamo respecto al ingreso incrementa adicionalmente el riesgo dentro de múltiples categorías crediticias.

Los resultados sugieren que los perfiles caracterizados simultáneamente por:

peor clasificación crediticia + alta carga del préstamo respecto al ingreso presentan las mayores tasas de incumplimiento.

Por lo tanto, ambas variables deberían considerarse conjuntamente en la identificación de perfiles de alto riesgo, en lugar de utilizarse de manera aislada.

5.3 Loan Intent vs. Income Burden

5.3.1 Objetivo

Analizar conjuntamente el propósito del préstamo (`loan_intent`) y la proporción que representa el préstamo respecto al ingreso del solicitante (`loan_percent_income`) para determinar si el efecto de la carga financiera sobre el incumplimiento se mantiene entre diferentes tipos de préstamo.

Adicionalmente, se busca determinar si `loan_intent` aporta información adicional para identificar segmentos con mayor o menor riesgo crediticio.

5.3.2 Resultados

Loan Intent	Q1 ≤9%	Q2 9–15%	Q3 15–23%	Q4 >23%
Debt Consolidation	17.12%	17.11%	26.64%	55.57%
Education	8.13%	8.96%	13.49%	40.66%
Home Improvement	15.82%	19.40%	26.42%	47.24%
Medical	15.34%	16.92%	22.58%	52.90%
Personal	10.31%	10.93%	15.95%	45.43%
Venture	4.71%	6.76%	11.32%	39.14%

5.3.3 Análisis

Los resultados muestran que `loan_percent_income` mantiene una relación consistente con el riesgo de incumplimiento independientemente del propósito del préstamo.

En **todos los tipos de préstamo**, el segmento Q4 (`loan_percent_income > 23%`) presenta la mayor tasa de incumplimiento.

Por ejemplo:

- DEBTCONSOLIDATION: 17.12% → 17.11% → 26.64% → **55.57%**
- MEDICAL: 15.34% → 16.92% → 22.58% → **52.90%**
- VENTURE: 4.71% → 6.76% → 11.32% → **39.14%**

Esto refuerza la evidencia encontrada en análisis anteriores de que una carga financiera elevada constituye uno de los principales indicadores de riesgo dentro del portafolio.

Sin embargo, el propósito del préstamo también permite diferenciar el nivel de riesgo.

Manteniendo un nivel similar de carga financiera, DEBTCONSOLIDATION y MEDICAL presentan generalmente mayores tasas de incumplimiento, mientras que VENTURE y EDUCATION presentan tasas relativamente menores.

Por ejemplo, dentro de Q1 ($\leq 9\%$), el `default_rate` varía desde **4.71% para VENTURE** hasta **17.12% para DEBTCONSOLIDATION**, a pesar de que todos los préstamos pertenecen al mismo segmento de carga financiera.

El contraste se vuelve aún más marcado al combinar ambos factores. El segmento:

VENTURE + carga $\leq 9\%$ → 4.71% de default

presenta un comportamiento considerablemente diferente de:

DEBTCONSOLIDATION + carga $> 23\%$ → 55.57% de default

Esto indica que ambas variables aportan información complementaria para la segmentación del riesgo.

5.3.4 Conclusión

`loan_percent_income` mantiene una fuerte asociación con el incumplimiento independientemente del propósito del préstamo. Una carga superior al **23% del ingreso** está asociada con un incremento considerable del `default_rate` en las seis categorías analizadas.

Al mismo tiempo, `loan_intent` aporta capacidad adicional de segmentación. Los préstamos destinados a **debt consolidation** y **medical** presentan generalmente mayor riesgo relativo, mientras que **venture** y **education** muestran menores tasas de incumplimiento bajo niveles comparables de carga financiera.

Por lo tanto, los resultados sugieren que el propósito del préstamo debe considerarse conjuntamente con la capacidad de pago relativa para identificar perfiles de mayor riesgo.

5.4 Perfil final de alto riesgo

5.4.1 Objetivo

Construir un perfil de alto riesgo combinando los factores que mostraron mayor capacidad para segmentar el incumplimiento durante el análisis:

- `loan_grade`: clasificación crediticia.
- `loan_percent_income`: carga del préstamo respecto al ingreso.
- `loan_intent`: propósito del préstamo.

El objetivo es identificar **combinaciones de características asociadas con las mayores tasas de incumplimiento**, en lugar de analizar cada variable de manera aislada.

Para reducir el impacto de segmentos con muy pocas observaciones, se consideraron únicamente combinaciones con **al menos 50 préstamos**.

5.4.2 Metodología

Se utilizó una **CTE (WITH)** para transformar `loan_percent_income` en cuatro grupos de carga financiera:

Grupo	Loan Percent Income
Q1	$\leq 9\%$
Q2	$>9\% - 15\%$
Q3	$>15\% - 23\%$
Q4	$>23\%$

Posteriormente, los préstamos fueron agrupados por:

`loan_grade + loan_intent + income_burden_group`

Para cada combinación se calcularon el número total de préstamos, préstamos en incumplimiento y tasa de incumplimiento.

Finalmente, se aplicó:

HAVING COUNT(*) >= 50

para excluir segmentos extremadamente pequeños y se ordenaron los resultados por default_rate de mayor a menor.

5.4.3 Principales resultados

Los perfiles con mayor tasa de incumplimiento fueron:

Grade	Intent	Burden	Loans	Defaults	Default Rate
E	Debt Consolidation	Q4	57	57	100%
E	Medical	Q4	65	63	97%
D	Debt Consolidation	Q4	186	176	95%
D	Debt Consolidation	Q1	129	123	95%
D	Debt Consolidation	Q3	161	149	93%
D	Medical	Q4	219	198	90%
D	Medical	Q2	151	134	89%
D	Debt Consolidation	Q2	122	107	88%
D	Medical	Q3	177	153	86%

D	Medical	Q1	108	91	84%
---	---------	----	-----	----	-----

5.4.4 Análisis

Los resultados muestran una fuerte concentración del riesgo en préstamos con **grades D–E**, particularmente cuando el propósito corresponde a DEBTCONSOLIDATION o MEDICAL.

Un hallazgo importante es que, dentro de determinados perfiles, la elevada tasa de incumplimiento se mantiene incluso cuando `loan_percent_income` es relativamente bajo.

Por ejemplo, para **Grade D + DEBTCONSOLIDATION**, las tasas observadas fueron:

- Q1: **95%**
- Q2: **88%**
- Q3: **93%**
- Q4: **95%**

De manera similar, **Grade D + MEDICAL** presentó:

- Q1: **84%**
- Q2: **89%**
- Q3: **86%**
- Q4: **90%**

Esto indica que la carga financiera no debe interpretarse aisladamente. Aunque `loan_percent_income` mostró una fuerte asociación con el incumplimiento en el portafolio general, determinadas combinaciones de **grade + intent** presentan un riesgo elevado independientemente del segmento de carga.

Por otro lado, cuando coinciden múltiples señales desfavorables —como un grade deteriorado, un propósito de mayor riesgo y una carga financiera elevada— aparecen algunos de los segmentos con mayores tasas de incumplimiento del conjunto de datos.

Los resultados correspondientes a segmentos cercanos al mínimo de 50 observaciones deben interpretarse con mayor cautela que aquellos respaldados por grupos de mayor tamaño.

5.4.5 Conclusión

El análisis multivariable demuestra que el riesgo de incumplimiento **no depende de una única característica**, sino de la combinación de diferentes factores.

Los perfiles de mayor riesgo se concentran principalmente en:

Grades D–E + préstamos para Debt Consolidation o Medical

La elevada carga financiera (`loan_percent_income > 23%`) constituye una señal importante de riesgo en el portafolio general y puede agravar determinadas combinaciones. Sin embargo, en perfiles ya altamente riesgosos, como **Grade D + Debt Consolidation** y **Grade D + Medical**, las tasas de incumplimiento permanecen elevadas incluso en niveles inferiores de carga financiera.

Por lo tanto, la segmentación conjunta de **clasificación crediticia, capacidad de pago relativa y propósito del préstamo** proporciona una identificación del riesgo más precisa que el análisis aislado de cualquiera de estas variables.

Este análisis es descriptivo y muestra asociaciones dentro del dataset; no demuestra causalidad ni constituye por sí mismo un modelo predictivo de probabilidad de default.

6. Hallazgos principales

6.1 La proporción del préstamo respecto al ingreso es un indicador clave de riesgo

`loan_percent_income` mostró una de las asociaciones más consistentes con el incumplimiento dentro del conjunto de datos.

A medida que el préstamo representa una mayor proporción del ingreso del solicitante, la tasa de incumplimiento tiende a aumentar considerablemente. En particular, el segmento donde el préstamo representa **más del 23% del ingreso** presentó repetidamente tasas de incumplimiento superiores.

Este comportamiento se mantuvo incluso al analizar `loan_percent_income` conjuntamente con otras características, como el monto, el grado crediticio y el propósito del préstamo.

Por lo tanto, la proporción del préstamo respecto al ingreso constituye uno de los principales indicadores identificados para evaluar la capacidad de pago y segmentar el riesgo crediticio.

6.2 El grado crediticio presenta una fuerte relación con el riesgo de incumplimiento

`loan_grade` mostró una fuerte asociación con el comportamiento de pago. Conforme se deteriora la clasificación crediticia, las tasas de incumplimiento aumentan considerablemente, especialmente a partir de los grados D y posteriores.

Sin embargo, el análisis combinado demostró que el grado crediticio no debe interpretarse de manera completamente aislada.

Dentro de un mismo grado, diferentes niveles de `loan_percent_income` pueden producir variaciones importantes en la tasa de incumplimiento. Por ejemplo, los préstamos Grade A

presentaron tasas relativamente bajas en los primeros segmentos de carga financiera, pero alcanzaron un **34.50% de incumplimiento** cuando el préstamo representaba más del 23% del ingreso.

Por lo tanto, `loan_grade` constituye un indicador relevante de riesgo, pero su interpretación mejora cuando se combina con variables relacionadas con la capacidad de pago.

6.3 La carga relativa del préstamo es más informativa que el monto absoluto

El análisis individual de `loan_amnt` mostró inicialmente que los préstamos pertenecientes al segmento de mayor monto presentaban una tasa de incumplimiento superior.

Sin embargo, al analizar conjuntamente `loan_amnt` y `loan_percent_income`, la relación entre el monto absoluto y el incumplimiento perdió consistencia.

Los préstamos de alto monto podían presentar tasas relativamente bajas cuando representaban una pequeña proporción del ingreso del solicitante. Al mismo tiempo, préstamos de menor monto podían presentar tasas de incumplimiento considerablemente superiores cuando suponían una carga elevada respecto al ingreso.

Esto indica que **el tamaño absoluto del préstamo proporciona menos información sobre el riesgo que el tamaño del préstamo en relación con la capacidad económica del solicitante.**

Por lo tanto, `loan_percent_income` resulta más informativo para la evaluación del riesgo que `loan_amnt` considerado de manera aislada.

6.4 El propósito del préstamo aporta información adicional sobre el riesgo

`loan_intent` mostró diferencias relevantes en las tasas de incumplimiento entre los distintos propósitos del préstamo.

Los préstamos destinados a **consolidación de deuda (DEBTCONSOLIDATION)** y **gastos médicos (MEDICAL)** tendieron a presentar mayores tasas de incumplimiento bajo niveles comparables de carga financiera.

En contraste, categorías como **emprendimiento (VENTURE)** y **educación (EDUCATION)** presentaron generalmente menores tasas de incumplimiento.

Estas diferencias permanecieron visibles incluso después de segmentar los préstamos de acuerdo con `loan_percent_income`, lo que indica que el propósito del préstamo aporta información adicional para la identificación de segmentos de riesgo.

6.5 El riesgo se comprende mejor mediante la combinación de múltiples factores

Uno de los principales hallazgos del análisis fue que el riesgo crediticio puede interpretarse de manera más precisa mediante la combinación de distintas características, en lugar de analizar cada variable de forma completamente aislada.

El análisis conjunto de:

- loan_grade
- loan_percent_income
- loan_intent

permitió identificar segmentos con comportamientos de pago considerablemente diferentes.

Esto demuestra que un solo indicador no proporciona necesariamente una visión completa del riesgo. Un solicitante puede presentar una característica favorable y, al mismo tiempo, otra característica que incremente considerablemente su nivel de exposición.

La combinación de clasificación crediticia, capacidad de pago relativa y propósito del préstamo permitió obtener una segmentación más detallada del comportamiento de incumplimiento.

6.6 Perfil de alto riesgo identificado

El análisis multivariable permitió identificar una concentración particularmente elevada del riesgo en préstamos correspondientes a **grades D–E**, principalmente cuando el propósito del préstamo era **consolidación de deuda (DEBTCONSOLIDATION)** o **gastos médicos (MEDICAL)**.

Entre los segmentos con al menos 50 observaciones se encontraron combinaciones con tasas de incumplimiento superiores al **80%**, y algunas cercanas o iguales al 100%.

Además, una carga financiera superior al **23% del ingreso** apareció repetidamente como una señal importante de riesgo en el portafolio general.

Sin embargo, el análisis final mostró que determinadas combinaciones de loan_grade y loan_intent, particularmente **Grade D + Debt Consolidation** y **Grade D + Medical**, mantuvieron tasas de incumplimiento muy elevadas incluso en segmentos con menor loan_percent_income.

Esto indica que el perfil de riesgo no puede definirse únicamente mediante un límite de carga financiera, sino mediante la interacción entre diferentes características.

En términos generales, el perfil de mayor riesgo identificado dentro del conjunto de datos se caracteriza principalmente por:

Grados crediticios D–E + préstamos destinados a consolidación de deuda o gastos médicos, con una carga elevada del préstamo respecto al ingreso como factor adicional de riesgo.

6.7 Conclusión general

El análisis muestra que el riesgo de incumplimiento se encuentra asociado con múltiples características del préstamo y del solicitante, pero no todas presentan el mismo nivel de relevancia.

loan_percent_income destacó como uno de los indicadores más consistentes de riesgo, mostrando un incremento considerable del incumplimiento cuando el préstamo representa una proporción elevada del ingreso.

loan_grade también presentó una fuerte asociación con el comportamiento de pago, especialmente en las categorías de mayor riesgo. Por su parte, loan_intent permitió identificar diferencias adicionales entre préstamos con características financieras similares.

En contraste, variables como el monto absoluto del préstamo mostraron una capacidad explicativa más limitada una vez consideradas conjuntamente con indicadores relativos de capacidad de pago.

El análisis multivariable permitió concluir que **la combinación de clasificación crediticia, carga financiera relativa y propósito del préstamo proporciona una segmentación del riesgo más informativa que la utilización aislada de cualquiera de estas características.**

Estos hallazgos pueden utilizarse como base para desarrollar estrategias de segmentación, monitoreo y evaluación del riesgo crediticio.

Nota metodológica: Este análisis es descriptivo e identifica asociaciones entre las características de los préstamos y el comportamiento de incumplimiento dentro del conjunto de datos analizado. Los resultados no deben interpretarse como relaciones causales ni como un modelo predictivo de probabilidad de incumplimiento.

7. Recomendaciones de negocio

7.1 Priorizar la capacidad de pago relativa

La evaluación de nuevas solicitudes debería considerar especialmente la proporción que representa el préstamo respecto al ingreso del solicitante (loan_percent_income).

Los resultados muestran un incremento considerable del incumplimiento cuando esta proporción supera el **23%**, por lo que este nivel puede utilizarse como **señal de alerta para una revisión adicional**, y no necesariamente como criterio automático de rechazo.

7.2 Evaluar múltiples factores de riesgo de manera conjunta

La aprobación y evaluación de préstamos no debería depender exclusivamente de una sola característica.

Los resultados muestran que la combinación de `loan_grade`, `loan_percent_income` y `loan_intent` permite distinguir perfiles de riesgo con mayor precisión que cualquiera de estas variables por separado.

Por ello, se recomienda utilizar una evaluación multivariable que considere simultáneamente la clasificación crediticia, la capacidad de pago relativa y el propósito del préstamo.

7.3 Reforzar la revisión de préstamos para consolidación de deuda y gastos médicos

Los préstamos destinados a **consolidación de deuda y gastos médicos** presentaron mayores tasas de incumplimiento que otras categorías bajo condiciones comparables.

Estas solicitudes podrían someterse a controles adicionales, especialmente cuando coinciden con un `loan_grade` deteriorado o una carga financiera elevada.

Esto no implica rechazar automáticamente estos propósitos, sino utilizarlos como una **señal adicional dentro de la evaluación integral del riesgo**.

7.4 Implementar alertas para combinaciones de alto riesgo

Los perfiles correspondientes a **Grades D–E combinados con Debt Consolidation o Medical** presentaron algunas de las mayores tasas de incumplimiento del portafolio.

Se recomienda establecer mecanismos de alerta para identificar estas combinaciones durante el proceso de evaluación y aplicar medidas como revisión adicional, ajustes en las condiciones del préstamo o controles de exposición, dependiendo de las políticas de riesgo de la institución.

7.5 Utilizar el monto del préstamo dentro del contexto financiero del cliente

El monto absoluto del préstamo (`loan_amnt`) no debería utilizarse de manera aislada como indicador principal de riesgo.

Los resultados mostraron que un préstamo elevado puede presentar un riesgo relativamente bajo cuando representa una proporción pequeña del ingreso, mientras que un préstamo de menor monto puede representar una carga considerable para un solicitante con ingresos bajos.

Por lo tanto, se recomienda evaluar el monto solicitado principalmente **en relación con la capacidad económica del cliente**.

Conclusión

Las recomendaciones anteriores se derivan de patrones observados en el conjunto de datos y deberían utilizarse como apoyo para la segmentación y evaluación del riesgo, no como reglas automáticas de aprobación o rechazo.

Cualquier política crediticia implementada a partir de estos hallazgos debería validarse mediante análisis adicionales y modelos de riesgo apropiados antes de utilizarse en decisiones reales de otorgamiento de crédito.